Kaggle近期（2026年1月30日附近）选题报告

> 下面这份《选题报告 + 参赛导航》我按你给的**清单原文**与**团队约束**直接补全成“可以立刻开跑”的版本；所有关键结论都尽量给到【事实】依据与【推断】建议，并把**规则风险**集中进“风险登记表”。

快速可行动版本（不问你也能开跑）

我建议的 Top-3（按优先级）

1. **WiDS Global Datathon 2026（野火 time-to-threat / 多时间窗概率预测）**
   - 【事实】赛程长、截止到 **2026-05-01 23:59 UTC**（JST=**2026-05-02 08:59**）。
   - 【事实】评估是**删失处理（censoring）+ 加权 Brier score**，权重 **0.3/0.4/0.3 对应 24/48/72 小时**（48h 最关键）。
   - 【推断】你们 8GB 显存完全够：这题强 baseline 用 **LightGBM/CatBoost + 校准**即可，GPU不是瓶颈；更适合“学习+产出可复用 pipeline”。
2. **Jaguar Re-Identification Challenge（CV 检索 / ReID 度量学习）**
   - 【事实】检索指标是 **Identity-Balanced mAP**（每只豹等权）。
   - 【事实】规则允许“**低成本、可获得**”的外部数据/模型，但禁止昂贵私有资源。
   - 【推断】非常适合你们的 CV 栈：用 **预训练 backbone + embedding + metric loss + kNN 检索**，48 小时内能打出像样 baseline；8GB 也能用 AMP + 小 batch 跑起来。
3. **Deep Past Challenge – Translate Akkadian to English（NLP 低资源机器翻译 + 文本规范化）**
   - 【事实】评分是 **几何平均：sqrt(BLEU × chrF++)**。
   - 【事实】规则明确允许外部数据/工具（但要合规）。
   - 【推断】这题“格式即信息”(你已经总结得很对)：核心学习价值在 **tokenization/规范化/命名实体处理/评估对齐**；8GB 适合走 **ByT5-small/LoRA**路线（冲更高再考虑云）。

> **AIMO PP3** 我放在“强备选/长期项目”：它学习价值极高，但工程成本也最高（受 notebook 限制与推理预算约束）。

立刻启动的 12 个 ToDo（按优先级）

1.（全赛通用）建立仓库结构：`data/`（只放Kaggle输入引用）、`src/`、`notebooks/`、`reports/`、`submission_log.md`、`risk_register.md`。
2.（全赛通用）把“**规则红线**”写进 `risk_register.md`：外部数据、泄漏、与队伍合并截止。
3.（WiDS）用官方删失口径构造 24/48/72 标签 + GroupKFold（按 fire/zone 分组，避免泄漏）。
4.（WiDS）先做 **LGBM 三模型（24/48/72）+ isotonic 校准 + 单调化 p24≤p48≤p72**，先把 48h 做稳。
5.（Jaguar）下载数据后先跑一个“冻结 backbone + 线性头”的 embedding baseline；推理用 cosine + kNN 输出排序。
6.（Jaguar）补上强增强（crop/blur/illumination/occlusion）+ ArcFace/Triplet 二选一，做最小 ablation。
7.（DeepPast）实现你提到的**规范化器**（`-`、`{}`、大小写、gap、标点空格），并做“开/关对照实验”。
8.（DeepPast）先训 **ByT5-small**（或小 T5）+ sacrebleu 复现 BLEU/chrF++ 本地评估口径。
9.（DeepPast）用 lexicon 做专名一致性后处理（先规则替换，再看是否需要 constrained decoding）。
10.（AIMO，若启动）先做“**稳输出格式** + 小模型 + 自一致投票（受惩罚项约束）”的可运行系统，争取可提交闭环。
11.（全赛通用）建立 `cv_design.md`：每次提交必须附带“CV划分/随机种子/是否用外部数据”的摘要。
12.（全赛通用）在 W&B 或简化版日志里记录：特征版本、模型版本、CV 分数与方差、LB 分数与差值。

仍需要查询与确认的清单

1. 你们两位主力的**性别身份**:均为男性（WiDS可能“中风险”）。
2. WiDS 2026 **Rules 页面**里对“外部数据/预训练模型”的精确条款（WiDS 往届有的禁外部、有的允许，必须以本届为准）。
3. 你们更想主战 **CV 还是 NLP**（决定 Jaguar vs DeepPast 的优先投入比例）。
4. 你们能否接受“**只在 Kaggle Notebook 训练/推理**”(若 Code Competition 限制更严，本地 GPU 主要用于试验)。

5. 云预算大概量级（哪怕是“0/小额/可报销/可冲一次大机”这种粗粒度）。
6. 你们希望最终交付物：notebook + 复盘+“可放作品集”的技术报告/博文。
7. DeepPast：你们是否愿意用外部语料（即便规则允许也要注意许可；你已明确“不合规坚决不碰”，我会按这个执行）。
8. WiDS：目标是纯学习（会影响是否必须满足 WiDS 队伍性别规则）。

I. 一页决策摘要（Executive Summary）

推荐 Top-3（按优先级）

1) WiDS Global Datathon 2026（主战场候选）

为什么适合我们（3-5条）

- 【事实】评分是**加权 Brier（24/48/72）+ 删失剔除**，非常训练“概率预测 + 校准 + CV 设计”。
- 【事实】赛程到 2026-05-01，迭代空间大；你们“最晚结束前三天”也能安排 3-4 轮稳定迭代。
- 【推断】强 baseline 不靠大模型：LGBM/CatBoost + 校准 + 单调约束就能学到很多“工程化获胜点”。
- 【推断】题目与“火灾蔓延/威胁范围”高度相关，你们明确愿意考虑该方向，学习契合度高。

最大风险（1-3条）

- 【事实→推断】WiDS 系列常见“队伍至少 50% 女性成员”资格要求；若你们不满足，可能影响“官方认可/奖项/榜单资格”。（需以 2026 Rules 最终措辞核验）
- 【推断】若 CV 划分没按 fire/zone 分组，极易“看起来分高、上线翻车”（隐形泄漏）。

成功概率/投入产出（定性）

- 【推断】**成功概率：高（学习目标）**；投入主要是特征与 CV/校准，算力压力低，产出可复用性强。

---

2) Jaguar Re-Identification（副战场候选）

为什么适合我们

- 【事实】指标是 Identity-Balanced mAP，典型检索任务，能系统练 **metric learning + 召回/排序**。
- 【事实】LB 仅用约 48% 测试，final 用剩余 52%，对“稳 CV + 不过拟合”是好训练。
- 【推断】8GB 显存也能跑：AMP + 小 batch + 轻 backbone；想冲更高再上云或更大 backbone。
- 【事实】允许“低成本可获得”的外部模型/数据（合规前提下）。

最大风险

- 【推断】同一只豹跨相机域差异大（夜视/遮挡/角度），若增强策略弱，embedding 学不稳。
- 【推断】如果用外部数据，合规与“可获得性”要写清楚，否则规则风险上升。

成功概率/投入产出

- 【推断】**成功概率：中高（学习目标）**；短期能出成绩与可展示 pipeline，投入集中在训练/增强/检索评估。

---

3) Deep Past MT（备选但很值得）

为什么适合我们

- 【事实】评分是 sqrt(BLEU×chrF++)，逼你同时兼顾“词级匹配”和“字符级鲁棒性”，非常利于学习评估对齐。
- 【事实】规则允许外部数据/工具（合规可用）。
- 【推断】你已经抓住核心：**格式标记（{}、-、大小写、gap）是语言的一部分**，这题训练“数据规范化工程”含金量很高。
- 【推断】8k 级数据规模适合做扎实的 ablation ladder（而不是纯堆算力）。

最大风险

- 【推断】命名实体与标点空格对 BLEU 极敏感：后处理做不好，模型再强也白搭。
- 【推断】若 CV 切分没按来源/文档分组，LB 过拟合风险高。

成功概率/投入产出

- 【推断】**成功概率：中（学习目标高）**；工程投入在清洗/tokenizer/后处理，算力中等（必要时上云）。

结论

- **主战场：WiDS Global Datathon 2026**（最贴合你们“学习+稳定产出+不过度吃算力”）。
- **备选1：Jaguar ReID**（CV 方向快速闭环、可作品集）。
- **备选2：Deep Past MT**（NLP 方向差异化、数据工程味很浓）。

II. 赛题卡片（每题一张）

A) WiDS Global Datathon 2026（WiDSWorldWide_GlobalDathon26）

1)【事实】关键规则

- 起止：Start **2026-01-28**；Final **2026-05-01 23:59 UTC**（JST 5/2 08:59）。
- 任务：预测疏散区在多个 horizon 内被 threat 的概率（官方强调 survival analysis 视角）。
- 指标：删失处理 + 加权 Brier：**0.3×24h + 0.4×48h + 0.3×72h**；删失在 H 前的样本排除。
- 组队限制：WiDS 系列常见“至少 50% 女性成员（identify as females/women）”，但**是否影响参赛/上榜/获奖**需以 2026 Rules 最终措辞核验。

> 外部数据/预训练/推理限制：**本届需要你们在 Rules 页面逐条核验**（WiDS 往届口径有差异）。

2)【事实】任务类型判定

- Tabular + Time-to-event（生存分析/多时间窗概率预测）。

3)【推断】难点地图

- 删失处理若做错：本地 CV 与线上评分会“系统性偏差”。
- 泄漏高发：同一场 fire/同一 evacuation zone 在训练/验证穿插，会把时空相关性当成“模型能力”。
- Brier 强惩罚“过度自信”：概率校准差会直接掉分（这不是 AUC）。
- 多 horizon 一致性：p24≤p48≤p72 若不满足，很多样本会显著拉低 Brier（尤其 48h 权重大）。

4) 能力点需求（分层）

- 入门必备（1-2天补齐）：删失标签构造、Brier/校准（isotonic/Platt）、GroupKFold。
- 核心壁垒：按事件结构设计 CV（按 fire/zone/time 分组）、稳定的校准与单调约束、特征时序一致性。
- 冲榜技巧：多任务共享表示（24/48/72 联训）、生存模型输出 S(t)/F(t)、stacking + 校准二次优化。

5) 数据与指标的策略含义

- Brier 对“校准/概率幅度”非常敏感：
  - 你不能只把排序做对；必须让概率接近真实频率。
- CV 设计：强烈建议 **按 fire 或 evacuation zone 分组**，再按时间切，避免“同源泄漏”。（推断但几乎是这类题的常规胜负手）

6) 最小可行 baseline（MVP）路线

- 强基线：三套 LightGBM（24/48/72）或 CatBoost。
- 管线草图：

1. 读入 → 生成 y24/y48/y72（删失在 H 前的样本剔除）
2. GroupKFold（group=fire_id 或 zone_id）
3. 训练 → 预测概率 → isotonic 校准
4. 单调化：`p48=max(p48,p24)`，`p72=max(p72,p48)`

- 48 小时保底（定性）：能做出“CV 稳定、线上不崩”的 baseline（不追名次也足够用于学习复盘）。

7) 提升路线（Ablation Ladder，8-12项）

1. 校准（isotonic/Platt）【收益高/成本低/风险低】
2. Group 设计（fire/zone）【高/低/低】
3. 缺失值策略（missingness as signal）【中高/低/低】
4. 分 horizon 的特征子集（更贴近 early-signal）【中/中/低】
5. 目标重加权（贴近 48h 权重）【中/低/低】
6. 单调约束与后处理【中/低/低】
7. 生存模型（Cox/AFT/GBM-survival）【中/中高/中】
8. 多任务共享（共享 backbone + 多头）【中/中/中】
9. Stacking（LGB + survival + NN）【中/中/中】
10. 不确定性估计（温度缩放/分位校准）【低中/中/低】
11. 特征交互（target encoding/交叉统计）【低中/中/中】
12. 细粒度时间窗（12h 作为辅助任务）【低中/中/低】

8) 资源评估

- 主要吃 CPU/内存；GPU可有可无。你们 8GB 显存不会限制本题。

9) 论坛/历史先例关键词

- “censoring excluded”、“Brier score calibration”、“survival analysis”、“GroupKFold leakage”。

B) Jaguar Re-Identification Challenge（jaguar-re-id）

1)【事实】关键规则

- 指标：Identity-Balanced mAP（macro-averaged，保证每只豹等权）。
- LB/Final：LB 约用 48% 测试，Final 用剩余 52%。
- 外部数据/模型：允许，但需“minimal cost & reasonably accessible”；禁止昂贵私有资源。
- 时间线与提交形态：以 Kaggle 竞赛页为准（你之前给了 CET 时间口径；我在风险表里按“需核验”处理）。

2)【事实】任务类型判定

- CV / Metric Learning / Image Retrieval。

3)【推断】难点地图

- 域差异：夜视、雨天、泥水、遮挡、近景/远景导致纹理不可见。
- 身份不平衡：某些豹样本多、某些豹样本少；指标虽平衡，但训练仍会被头部身份带偏。
- 过拟合增强：增强过强会伤害细粒度纹理（斑纹是关键信号）。

4) 能力点需求

- 入门必备：embedding + cosine/kNN；基本增强；mAP 评估。
- 核心壁垒：metric loss（ArcFace/Triplet/CircleLoss）、hard mining、domain-robust augmentation。
- 冲榜技巧：多模型/多尺度、test-time augmentation、聚类伪标签/自训练（谨慎，易翻车）。

5) 指标策略含义

- mAP 本质吃“排序质量”：
  - 重点是 **embedding 可分性**与 **同豹聚类紧、异豹分离开**；阈值校准不如 WiDS 重要。
- CV 划分：建议按“个体 ID”分层 + 场景分组（避免同一拍摄条件泄漏）。

6) MVP baseline（48h 内）

- 强基线：`timm` 预训练 backbone（如 EfficientNet/ConvNeXt-Tiny）+ embedding head（512/1024）
- Loss：ArcFace 或 Triplet（二选一先跑通）
- 推理：normalize embedding → cosine similarity → 排序输出
- 48h 保底：能稳定提交、并通过 ablation 看清“增强/损失/embedding 维度”的方向性。

7) 提升路线（8-12项）

1. 更强增强（illumination/blur/occlusion）【高/中/中】
2. ArcFace vs Triplet 系统对比【中高/中/低】
3. Hard mining（batch-hard）【中/中/中】
4. Balanced sampler（按 identity 均衡采样）【中/低/低】
5. 分辨率/裁剪策略（保纹理）【中/中/低】
6. 多 backbone 融合（2-3个轻模型）【中/中/中】
7. TTA（flip/resize）【低中/低/低】
8. 对齐/检测裁剪（先定位豹身）【低中/高/中】
9. 自训练伪标签【低中/高/高】
10. 重排序（k-reciprocal re-ranking）【低中/中/中】
11. CLIP/跨模态特征（谨慎）【低/高/中】
12. 去噪与重复样本处理【中/低/低】

8) 资源评估

- 8GB 显存可跑：AMP + batch 16/32（视分辨率）；推理轻。需要时云上 16-24GB 可显著提速。

9) 论坛/历史先例关键词

- “ReID strong baseline”、“ArcFace”、“Triplet batch-hard”、“re-ranking”。

C) Deep Past Challenge – Translate Akkadian to English（deep-past-initiative-machine-translation）

1)【事实】关键规则

- 指标：**Score = sqrt(BLEU × chrF++)**。
- 奖金：总奖池 **$50,000**（规则页列出分配）。
- 外部数据：规则明确允许外部数据与工具（必须合规与可追溯）。
- 赛题数据口径与实现建议：官方提到可参考 SacreBLEU。
- 时间线：Kaggle 页显示 Final **2026-03-23**（含 Entry/Team Merger 等节点需以页面为准）。

2)【事实】任务类型判定

- NLP / Seq2Seq 机器翻译（低资源 + 特殊转写格式）。

3)【推断】难点地图

- “格式即信息”：`-`、`{}`、大小写、gap、logogram 信号若被 tokenizer 破坏，会系统掉分。
- BLEU 对标点/空格/专名极敏感；chrF++ 让字符层面更重要 → 两头都要顾。
- LB 过拟合：来源/文本相似度高时，本地切分不严会导致“离线很美、线上一般”。

4) 能力点需求

- 入门必备：sacrebleu 复现指标；最小规范化器；基本 seq2seq（T5/ByT5）。
- 核心壁垒：tokenization 设计、命名实体一致性、lexicon 后处理、按来源分组 CV。
- 冲榜技巧：多模型蒸馏/集成、constrained decoding、best-of-n 采样与重排序（注意 BLEU/chrF++ 取舍）。

5) 指标“策略含义”

- BLEU：偏 n-gram 精确匹配 → **同义改写反而扣分**。
- chrF++：字符级更宽容 → 对拼写/形态变化更友好。
- 几何平均：短板放大 → 不能只优化其中一个。

6) MVP baseline

- 强基线：**ByT5-small**（byte-level，对 `{}` 、 `-` 更友好）
- 管线草图：
  1. 规范化（gap/空格/标点/ `{}` 作为特殊 token）
  2. 训练：label smoothing + teacher forcing
  3. 解码：beam search（先保守）
  4. 后处理：lexicon 专名统一 + 标点空格规则修复
- 48h 保底：能得到“可解释的增益曲线”(规范化开关、beam size、lexicon 后处理)。

7) Ablation Ladder（8-12项）

1. 规范化器 v1（gap/空格/标点）【高/低/低】
2. `{d}/{ki}` 等 determinatives：保留 vs 归一【高/低/中】
3. 大小写策略：不 lower vs 部分 lower【中高/低/中】
4. ByT5 vs T5（同训练预算）【中/中/低】
5. beam search 参数【中/低/低】
6. lexicon 专名统一【高/低/低】
7. 数据增强（噪声/格式扰动）【中/中/中】
8. 来源分组 CV【高/低/低】
9. 多 checkpoint 平均/集成【中/中/中】
10. best-of-n 生成 + 重排序【低中/中/中】
11. constrained decoding（专名强制）【低中/高/中】
12. 小规模外部语料（仅当许可合规）【中/高/高】

8) 资源评估

- 8GB：ByT5-small/LoRA OK；大模型或大 batch 可能要云（16-24GB 会舒服很多）。
- 训练时间可能偏长（社区也有用 12GB 仍觉得慢的反馈），所以“尽早固定规范化与 CV”是关键。

9) 论坛/历史先例关键词

- “ByT5”、“lexicon post-processing”、“SacreBLEU chrF++”、“format normalization”。

D) AI Mathematical Olympiad – Progress Prize 3（ai-mathematical-olympiad-progress-prize-3）

1)【事实】关键规则

- 评估：**Penalized Accuracy**（正确率 + 惩罚项）。
- 运行/提交流程：Notebook 提交；常见限制是 CPU 9h / GPU 5h（以规则页为准）。
- 时间线：Final **2026-04-15**；Entry/Team merger **2026-04-08**。
- 额外奖项可能要求“在指定时间前公开数据/成果”(如 Math Corpus Prize 有提前节点)。
- 规则变化趋势：讨论区提到 whitelisting 改动（需以 Rules 最终文本执行）。

2)【事实】任务类型判定

- LLM 数学推理 + 系统工程（解题、格式约束、资源约束下的推理策略）。

3)【推断】难点地图

- 不是“模型越大越好”：惩罚项会让“更长更慢”得不偿失。
- Notebook 限制下，检索/工具调用受限；需要“可控推理模板 + 轻量验证器”。
- 数据与题型分布可能随轮次变化，LB 过拟合风险高。

4) 能力点需求

- 入门必备：稳定输出格式、错误处理、简单投票/自一致策略。
- 核心壁垒：推理预算管理、程序验证/符号检查、答案规范化。
- 冲榜技巧：小模型多样性集成、轻量证明/检验、策略路由（不同题型走不同 solver）。

5) 指标策略含义

- Penalized Accuracy 通常意味着：**先对，再省**（省 token/省时/省不确定性）。

6) MVP baseline

- 小模型 + 固定解题模板 + 2-3 次采样投票（严格预算）+ 输出清洗器。
- 48h 保底：能跑通评测并在部分题型稳拿分。

7) Ablation Ladder（8-12项）

1. 输出格式与解析鲁棒性【高/低/低】
2. 题型路由（代数/几何/数论）【中/中/中】
3. 自一致投票（2→3→5）【中/中/中】
4. 轻量验证器（代入检验/单位检查）【中/中/中】
5. 温度/采样策略【中/低/低】
6. 失败回退策略（超时/无解）【中/低/低】
7. 小模型集成【中/中/中】
8. 蒸馏到更短推理【中/高/中】
9. 规则允许下的外部数学语料（需许可）【中/高/高】
10. 系统性能优化（缓存/并行）【低中/中/中】

8) 资源评估

- 你们本地 8GB 对“大模型”不友好，但 Kaggle notebook GPU 若更大可缓解；总体仍是工程受限赛。

9) 论坛/历史先例关键词

- “penalized accuracy”、“budgeted reasoning”、“self-consistency”。

III. 论文与资料导航（Reading Map）

> 规则提醒：以下是“可检索标题/作者/年份 +（部分给权威来源引用）”。涉及外部数据/模型时，一律以竞赛 Rules 为准，并记录许可与可获得性。

A) WiDS（生存分析 + 校准 + Brier）

Day1-2（先能跑通）

1. Brier score（概率评分规则经典定义）— Brier, 1950。
2. 概率校准：Platt scaling（Platt, 1999）；Isotonic（Zadrozny & Elkan, 2002）（可用标题检索）。

3. DeepSurv（深度生存分析 baseline）— Katzman et al., 2018。

Week1（把 CV/删失做对 + 稳定提升）

4. Random Survival Forests — Ishwaran et al., 2008（可检索）。
5. DeepHit — Lee et al., 2018（可检索）。
6. Time-dependent Brier score / IPCW（生存评估常用）— Graf et al., 1999（可检索）。

Week2（冲上限）

7. Gradient Boosting for Survival Analysis（AFT/GBM survival 系列，查“XGBoost survival/AFT”）。
8. Calibration for survival probabilities（查“survival calibration / isotonic survival”).
9. “leakage-aware CV for spatiotemporal data”（关键词检索：spatiotemporal leakage group CV）。

B) Jaguar ReID（度量学习 + 动物 ReID）

Day1-2

1. ArcFace — Deng et al., 2019。
2. FaceNet / Triplet loss — Schroff et al., 2015（可检索）。

Week1

3. Bag of Tricks and a Strong Baseline for Person ReID — Luo et al., 2019（可检索）。
4. Circle Loss — Sun et al., 2020（可检索）。
5. TransReID（Transformer for ReID）— He et al., 2021。

Week2（动物纹理更相关）

6. SealID: Saimaa Ringed Seal Re-Identification Dataset — Nepovinnykh et al., 2022（动物纹理挑战讨论很像）。
7. Species-Agnostic Patterned Animal Re-identification... — Nepovinnykh et al., 2024。
8. Re-ranking for ReID（k-reciprocal re-ranking）— Zhong et al., 2017（可检索）。

C) Deep Past（MT + byte-level + 评估对齐）

Day1-2

1. BLEU — Papineni et al., 2002。
2. chrF/chrF++ — Popović, 2017。
3. SacreBLEU（评估实现对齐）— Post, 2018（可检索；竞赛也提示参考）。

Week1

4. T5 — Raffel et al., 2020（可检索）。
5. ByT5 — Xue et al., 2021。
6. mBART — Liu et al., 2020（可检索）。

Week2

7. Lexically constrained decoding（Hokamp & Liu, 2017；Post & Vilar, 2018，可检索）。
8. Copy / Pointer-generator（See et al., 2017，可检索；对专名拷贝有启发）。
9. 近期“古语言/低资源翻译”综述或任务（如 ancient language translation workshop），可用 ACL Anthology 关键词检索。

D) AIMO PP3（推理系统）

Day1-2

1. Self-consistency（Wang et al., 2022，可检索）。
2. ReAct（Yao et al., 2023，可检索）。
3. PAL / program-aided reasoning（Gao et al., 2022，可检索）。

Week1-2

4. Toolformer（Schick et al., 2023，可检索）。
5. 预算约束下推理（关键词：budgeted reasoning, early exit, verifier）。
6. 竞赛讨论区（策略/限制变动）作为“事实更新源”。

IV. 选题想法库（Idea Bank）

> 每条都给：可测性（对照实验）、预计收益、失败信号。

A) WiDS（12-20 条）

A 数据视角

1. 缺失指示特征（missingness as signal）：开/关对照；收益中高；失败=CV方差变大。
2. 同一 zone 的历史统计（若规则允许使用训练内聚合）：对照；收益中；失败=LB涨CV不涨（泄漏嫌疑）。
3. 异常值截断（wind/temperature 等）：对照；收益中；失败=校准变差。

B 模型视角

4. 三个 horizon 独立模型 vs 多任务共享：对照；收益中；失败=单调性被破坏。
5. 生存模型输出 F(t) 再取 24/48/72：对照；收益中；失败=实现复杂但分不动。

C 训练视角

6. 48h 加权训练/样本权重：对照；收益中；失败=24/72 变差拖累总分。
7. 校准：isotonic vs Platt vs 温度缩放：对照；收益高；失败=CV Brier 降但 LB 不动（分布偏移）。

D 后处理与工程

8. 单调化 p24≤p48≤p72：对照；收益中；失败=单调化后反而 Brier 变差（说明模型本身学错了）。
9. 误差分析面板：按 fire/zone/time 分桶画 reliability diagram；收益高；失败=找不到系统性偏差。
10. Stacking 后二次校准：对照；收益中；失败=过拟合迹象（CV掉、LB涨）。

（其余略：你们真跑起来后，我可以按列名与数据 head() 再把想法扩到 20 条并更贴近特征类型。）

B) Jaguar ReID（12-20 条）

A 数据视角

1. 去重与坏图清洗：对照；收益中；失败=训练更难收敛。
2. 按 identity 做 balanced sampler：对照；收益中高；失败=mAP 不涨但 loss 降。

B 模型视角

3. Backbone：EffNet vs ConvNeXt-Tiny：对照；收益中；失败=推理变慢且 mAP 不涨。
4. Embedding 维度 256/512/1024：对照；收益中；失败=维度大但过拟合。

C 训练视角

5. ArcFace vs Triplet：对照；收益中高；失败=embedding collapse。
6. Hard mining：开/关；收益中；失败=训练不稳定。
7. Mixup/CutMix（谨慎）：对照；收益低中；失败=纹理被破坏导致 mAP 掉。

D 后处理与工程

8. k-reciprocal re-ranking：对照；收益低中；失败=LB涨Final翻（过拟合）。
9. TTA：flip/resize：对照；收益低；失败=速度不划算。
10. 误差分析：按夜视/白天分桶；收益高；失败=找不到改善方向。

C) Deep Past（12-20 条）

A 数据视角

1. gap 标记统一（`<gap>/<big_gap>`）：对照；收益高；失败=chrF++ 不升反降。
2. `{d}/{ki}` 保留为独立 token：对照；收益中高；失败=BLEU 升 chrF++ 降（过度机械）。
3. 大小写策略（不 lower）：对照；收益中；失败=专名更乱。

B 模型视角

4. ByT5-small vs T5-small：对照；收益中；失败=tokenizer 破坏格式导致 BLEU 崩。
5. LoRA 微调：对照；收益中；失败=训练更快但泛化更差。

C 训练视角

6. beam size/length penalty：网格对照；收益中；失败=输出更像英文但 BLEU 掉。
7. label smoothing：对照；收益低中；失败=收敛变慢。

D 后处理与工程

8. lexicon 专名统一：对照；收益高；失败=引入错误替换（专名歧义）。
9. 标点/空格规范化器：对照；收益中；失败=BLEU 震荡大。
10. 生成 N-best 后用 chrF++ 选：对照；收益低中；失败=过拟合评估口径。

D) AIMO（12-20 条）

1. 输出解析器（强约束）：对照；收益高；失败=解析失败率不降。
2. 题型路由：对照；收益中；失败=路由错误拖后腿。
3. 轻量验证器：对照；收益中；失败=验证成本>收益。
4. 预算化 self-consistency：对照；收益中；失败=惩罚项吞掉收益。

V. 选题报告（用于团队决策）

打分表（默认权重，可改）

- 时间匹配度 0.20（你们强调“别拖沓、最晚结束前三天”）
- 学习价值/可迁移性 0.25（你们目标=学习）
- 冲榜上限 0.10（不是主目标，但要看天花板）
- 资源可行性 0.15（8GB+可云）
- 规则风险 0.15（外部数据/组队资格/泄漏）
- 数据/指标稳定性 0.10（LB/Final 差异、评估噪声）
- 优势契合度 0.05（你们已有栈匹配度）

评分（定性→量化建议）

- **WiDS：8.6/10**（学习价值、资源可行、时间宽裕都强；主要扣分在“队伍资格/规则核验”）
- **Jaguar：8.2/10**（CV闭环快，适合作品集；主要扣分在“域差异导致不稳定 + 外部资源合规描述”）
- **DeepPast：7.8/10**（差异化强、数据工程味足；主要扣分在“规范化/评估对齐工作量与时间”）
- **AIMO：7.0/10**（学习价值爆炸高，但工程成本和限制也爆炸高；更适合作为长期副线）

Top-3 推荐与取舍

- **主选题：WiDS**
- **备选：Jaguar**（CV线）
- **备选：DeepPast**（NLP线）
- **放弃/后置：AIMO**（原因：投入产出对“短期学习闭环”不够友好，除非你们非常想练 LLM 系统工程）

VII. 风险登记表（Risk Register）

> 每题 ≥6 条；每条：触发条件 → 后果 → 规避策略 → 应急预案

WiDS（至少 6 条）

1. **队伍资格风险（50% 女性）**：不满足 → 可能影响官方榜/奖项/资格 → 立刻核验 2026 Rules；按要求组队 → 若无法满足：把 WiDS 当“练习题”但不追官方资格。
2. **删失处理错误**：标签构造不一致 → CV 与线上不一致 → 严格按评估说明实现剔除逻辑 → 写单元测试：对几个样本手算验证。
3. **时序穿越/泄漏**：同 fire/zone 跨折 → LB 虚高 Final 崩 → GroupKFold 按 fire/zone → 若已提交污染：回滚并重建 CV。

4. **概率未校准**：AUC 好但 Brier 差 → 分数上不去 → 强制做校准与 reliability diagram → 若校准让分更差：说明分布偏移，改 CV。
5. **单调性违反**：p24>p48 等 → Brier 拉低 → 后处理单调化 → 若单调化后更差：回到训练目标/特征设计。
6. **工程节奏拖沓**：最后一周才稳定 → 来不及复盘 → 设“硬停线=截止前 3 天” → 若落后：砍掉生存模型，只保 LGB+校准。

Jaguar（至少 6 条）

1. **域差异导致 embedding 不稳**：夜视/遮挡多 → mAP 不涨 → 强增强 + 分桶误差分析 → 若无改善：换 backbone/分辨率策略。
2. **身份不平衡**：头部身份主导训练 → 指标等权但模型偏 → balanced sampler + loss 调整 → 若仍偏：做 class-aware mining。
3. **外部资源合规不清**：用了外部数据/模型但不可获得 → 违规风险 → 只用“低成本可获得”并记录来源与许可 → 若有疑义：完全不用外部数据。
4. **LB/Final 差异**：LB 只用 48% → 线上调参过拟合 → 用稳健 CV + 少提交策略 → 若分数震荡：降低复杂后处理。
5. **过强增强破坏纹理**：loss 降但 mAP 掉 → 做增强 ablation → 回退增强强度。
6. **显存不足/训练慢**：8GB 卡死 → AMP + gradient accumulation → 若仍慢：云上 16-24GB 跑关键实验。

DeepPast（至少 6 条）

1. **格式信息丢失**：tokenizer 破坏 `{}` / `-` /大小写 → BLEU 掉 → ByT5/byte-level + 规范化器对照 → 若仍不行：把特殊符号显式加入词表。
2. **标点空格不一致**：BLEU 大幅波动 → 后处理统一规范 → 若误伤：只对高置信规则做修复。
3. **专名不一致**：同实体多拼法 → BLEU 亏 → lexicon 统一 → 若误替换：引入白名单与上下文条件。
4. **CV 切分不严**：LB 过拟合 → 来源/文档分组切分 → 若发现问题：重训并标记旧提交无效。
5. **外部数据许可风险**：规则允许但许可不合规 → 违规/下榜 → 只用许可清晰的公开资源；不确定就不用 → 应急：回退纯竞赛数据训练。
6. **训练耗时超预期**：迭代慢 → 先锁定规范化与小模型，再上云冲榜 → 若时间不足：只做后处理/集成小提升。

AIMO（至少 6 条）

1. **惩罚项吞收益**：推理太长太慢 → 分数反降 → 严格预算与早停策略 → 回退到更短策略。
2. **Notebook 限制**：超时/内存爆 → 轻量化模型与缓存 → 失败就减少采样次数。
3. **规则节点（奖项提交/公开要求）踩不到** → 影响资格 → 不追附加奖则忽略；追则提前排期
4. **题型分布变化**：调参过拟合 → 题型路由 + 多策略集成 → 若不稳：降低路由复杂度。
5. **答案格式错误**：对了也算错 → 强解析器 + 单元测试 → 若频繁：收紧输出模板。
6. **外部数据合规**：想用数学语料但许可不清 → 违规风险 → 只用许可清晰资源或完全不用 → 应急：回退纯 baseline。

关于你问的“WiDS 组队规则到底什么意思？所有 Kaggle 都要这样吗？”

- 【事实】WiDS 体系（国际挑战）在不少官方/FAQ口径里都有“**队伍 1-4 人，至少 50% 成员为女性/自我认同为女性**”的要求。
- 【推断】它**不是 Kaggle 的通用规则**，而是 WiDS 主办方的使命型限制；大多数 Kaggle 竞赛只规定“最多几人一队/何时截止合并”，不会限定性别。
- 【行动建议】对 WiDS 2026：**以本届 Rules 的 exact wording 为准**（有时影响“奖项/官方榜”，有时影响“资格本身”）。你们若不想在这上面冒险，就把 WiDS 当练习题做、但不追官方资格；或者按规则组队。